

GRADUAÇÃO 4D
PUCPR

Projeto da Disciplina – Etapa 3

AI Factory: Build, Deploy and Showcase

ANÁLISE CRÍTICA · BAHRD IA

Leonardo Campos · AI Factory: Build, Deploy and Showcase · PUCPR · novembro de 2026

Parte A · Revisitando o briefing

Acesso. Produção: https://bahrd.duckdns.org (login admin; senha na mensagem de entrega). Testes: https://bahrd-dev.duckdns.org (login leonardo). Código: https://www.github.com/Leonardolabdc/bahrd-ia.

Briefing. A Bahrd recebe cerca de 43 mil alertas de rastreamento por mês. Uma URA de regras fixas resolve boa parte, mas perto de 8 mil por mês escapam dela e viram atendimento manual, quase todos de rotina. O pedido era tirar esse trabalho do operador sem perder o controle dos casos graves e com auditoria.

Resolve no mecanismo e no custo: a IA confirma a causa e encerra pelo WhatsApp, ou entrega o caso com a conversa inteira, a R$ 0,13 por atendimento (Sonnet, medido; ≈ R$ 0,08 com o Haiku, o escolhido, estimado), contra R$ 1,00 a R$ 1,40 estimados com operador. Com áudio, os 8 mil casos custam ≈ R$ 4.100/mês, perto dos R$ 4.000 da URA atual. **Ainda não no resultado:** sem rastreadores reais, a meta de 50% de casos fechados sem operador não foi medida. **Em parte na auditoria:** a trilha existe, mas ainda não é gravada no Oracle.

Parte B · Defesa das decisões

1. Regra fixa antes da IA. Um motor de políticas determinístico decide o caminho de cada alerta: com mais de 90% de chance de ser real, o caso vai direto para uma pessoa, e a IA só encerra pelos desfechos autorizados. Atende ao controle do grave e à auditoria pedidos no briefing. Custo: cada tipo de evento novo exige política e playbook escritos.

2. Manter a stack herdada (ADR-001). Com os pesos fixados antes das notas, ela fez 4,35, contra 2,95 do Postgres único, pelo prazo de seis semanas e pela trilha resistente a adulteração. Preço: três bancos para uma pessoa operar.

3. Nuvem gratuita no Brasil e sessão no Redis (ADR-002 e ADR-003). R$ 0 de infraestrutura e dado no país. Como todo deploy reinicia a API, guardar a sessão no Redis faz a conversa sobreviver ao reinício. Limite: uma máquina de 1 GB por ambiente.

Funciona bem: nome, placa e endereço viram apelidos antes de chegar à IA, e o Langfuse mostra “Cliente” e “VEIC-001”; 1.107 testes, smoke tests e rollback de 33 a 37 segundos; e o cache de prompt corta 94,3% do custo a partir da segunda resposta.

Funciona mal: o modelo padrão, Gemini 2.5 Flash Lite, foi reprovado em medição, porque tratou um possível roubo como rotina; a IA chamou um cliente de “Bruno”, nome de exemplo que aparecia 14 vezes nos prompts; e sessões de teste presas no Redis a fizeram listar a mesma placa quatro vezes.

Limitações: alertas sintéticos; nada grava no Oracle nem no MySQL, e o expurgo de 90 dias roda em tabelas vazias; nome de terceiro em texto livre não é detectado; cache só com o Claude; usuários só na configuração; o banco gratuito para após 7 dias sem uso; segredo do webhook não combinado; sem telefonia.

Parte C · Visão de futuro e aprendizados

Roadmap v1.1: três propostas (o que muda, com que tecnologia, impacto esperado)

O que muda: A ideia dessa aplicação é automatizar os atendimentos de uma central de monitoramento com informações vindas de rastreadores e telemetria. Assim podendo mover o time de operadores

© PUCPR. Todos os direitos reservados. Nenhum texto pode ser reproduzido sem prévia autorização.

humanos para tarefas de maior risco e também poder ampliar a quantidade de clientes garantindo a eficiência da operação dando maior controle sobre os dados de forma agêntica e computadorizada, utilizando GenAI e técnicas de sistemas de dados inteligentes.

O que aprendi que não esperava aprender

Tive diversos insights e aprendizados durante essa disciplina, acredito que fui agraciado por ter a oportunidade de sincronizar o meu trabalho já em tecnologia focado 100% em IA junto com essa disciplina e todo o conhecimento de deploy e conceitos como CI/CD me fez enraizar esses conceitos, por incrível que pareça o conteúdo dessa displina aparecer exatamente na hora exata que estava precisando para aplicar no meu dia a dia do trabalho e ter essa ancora como trabalhar em máquinas de servidores solidificou bastante esses conceitos de trabalho em nuvem.

Como a experiência se conecta aos meus objetivos

Como disse no tópico anterior essa disciplina casou perfeitamente na hora exata em que precisava aprender esses conceitos da disciplina para aplicar no meu trabalho real e como objetivo a médio e longo prazo pretendo empreender utilizando o digital pela internet e assim criar um produto e ou serviço que realmente impacte positivamente a vida das pessoas de forma que a Inteligência Artificial melhore algo para as pessoas e ajude elas quem sabe a alcançarem seus objetivos particulares. E com as conteúdos dessa disciplina eu consegui me inserir com segurança de conhecimentos em um time de TI que trabalha presencial, o que eu almejava como estratégia para aprender mais na prática estando no dia a dia trabalhando em conjunto com eles até eu entender bem como funciona todas as áreas de desenvolvimento e soluções de softwares podendo assim criar solides de experiências e se tornar futuramente um techlead focado em IA conseguindo empreender na sequência.

O que faria diferente se recomeçasse

Eu acredito que o que mais me fez bater a cabeça foi dar o SSH nas máquinas da Oracle e organizar e cadastrar as chaves corretas de logs/traces do langfuse para funcionar de verdade no cluster, porque trabalhar pelo terminal do git bash utilizando um sistema Ubuntu que é uma distro Linux me trouxe a vontade de me aprofundar nos conhecimentos do kernel e sistema operacional Linux para começar a se aproximar cada vez mais dos comandos e usabilidades desse sistema que também é amplamente utilizandos em servidores, embarcados e diversos casos de uso s aonde tenham um computador/processador. Agora o que eu teria feito diferente se já tivesse o conhecimento que aprendi sofrendo na prática foi na quela hora onde as chaves do langfuse estavam com o prefixo e na região errada, provavelmente criaria um método de verificar mais consistente porque ali no terminal quando ainda não entendemos completamente o que cada comando do ubuntu quer dizer fica muito mais abstrato o que estamos fazendo e criando uma forma de saber se tudo está no lugar certo e de forma correta ajuda na hora de fazer essas configurações manuais em servidores.

© PUCPR. Todos os direitos reservados. Nenhum texto pode ser reproduzido sem prévia autorização.

GRADUAÇÃO 4D
PUCPR



© PUCPR. Todos os direitos reservados. Nenhum texto pode ser reproduzido sem prévia autorização.